Tartu Ülikool

Sotsiaalteaduste valdkond

Narva kolledž

Õppekava Infotehnoloogiliste süsteemide arendus

Yugan Polezhaev

E-KVIITUNGITEL PÕHINEVA KULUKATEGORISEERIMISE SÜSTEEMI ARENDAMINE JA HINDAMINE EESTI ISIKLIKU FINANTSJUHTIMISE JAOKS

Bakalaureusetöö

Juhendaja: M.Sc. Andre Sääsk

NARVA 2026

Olen koostanud töö iseseisvalt. Kõik töö koostamisel kasutatud teiste autorite tööd, põhimõttelised seisukohad, kasutatud kirjandusallikatest ja mujalt pärinevad andmed on viidatud.

Yugan Polezhaev

(allkiri, kuupäev)

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Yugan Polezhaev,

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose

E-kviitungitel põhineva kulukategoriseerimise süsteemi arendamine ja hindamine Eesti isikliku finantsjuhtimise jaoks,

mille juhendaja on M.Sc. Andre Sääsk,

reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada digitaalarhiivi DSpace kuni autoriõiguse kehtivuse lõppemiseni.

2. Annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi DSpace kaudu Creative Commonsi litsentsiga CC BY NC ND 4.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni.

3. Olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile.

4. Kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

Yugan Polezhaev

(kuupäev)

RESÜMEE

Development and Evaluation of an E-Receipt-Based Expense Categorisation System for Personal Finance Management in Estonia

Most personal finance tools categorise expenses at the transaction level, assigning a single merchant-based category such as “Groceries” to each supermarket purchase. This approach does not distinguish between different product types within a single receipt, leading to inaccurate spending overviews.

The goal of this bachelor thesis was to develop and evaluate a localised prototype that categorises supermarket expenses at the receipt line-item level and to determine the practical applicability of this approach in the Estonian context compared to the transaction-level baseline.

The theoretical part reviewed personal financial management concepts, limitations of merchant-level categorisation, approaches to receipt data extraction, rule-based versus machine-learning classification methods, and the COICOP-based simplified category scheme.

The empirical part described the prototype system, which automates receipt downloading from the Maxima AITÄH portal, extracts product rows from text-layer PDF receipts, classifies each row using a rule-based keyword dictionary, and matches receipts to bank transactions. A pilot study analysed 114 Maxima receipts (686 product rows, excluding deposits) over a nine-month period (02.07.2025–26.03.2026). Results showed that 40% of receipts contained products from more than one category and 16.1% of consumption spending (291.67 EUR) was categorised differently from the bank baseline. The rule-based classifier achieved 87% accuracy and a macro-F1 score of 0.78 on a manually labelled gold standard of 200 rows.

The study confirms that line-item categorisation is technically feasible for Estonian text-layer PDF receipts and provides a more detailed spending structure than the transaction-level approach, although the classifier has limitations with infrequent categories and keyword ambiguity.

Keywords: e-receipt, expense categorisation, personal financial management, rule-based classification, line-item data, COICOP

SISSEJUHATUS

Isikliku rahanduse haldamine toimub üha sagedamini digitaalteenuste kaudu. Mobiilipangad ja eelarverakendused pakuvad kasutajale automaatset kulude kategoriseerimist, mis võimaldab jälgida, millised kululiigid moodustavad suurima osa igapäevastest kulutustest. Sellise analüüsi praktiline väärtus sõltub aga kategooriate kvaliteedist: kui kulud on jaotatud liiga üldistesse rühmadesse, saab kasutaja moonutatud pildi oma tegelikust kulustruktuurist ja teeb otsuseid puudulike andmete põhjal (Struwig & Plaatjes, 2013).

Praktikas tuginevad pangandus- ja finantstehnoloogia lahendused kulude kategoriseerimisel enamasti tehinguandmetele — summale, kuupäevale ja müügikohale. Selle tulemusena satuvad supermarketites tehtud ostud sageli ühte ühisesse kategooriasse, näiteks „Toidupoed", kuigi tegelik ostukorv võib sisaldada nii toiduaineid, kodukeemiat, alkoholi kui ka muid kaupu (Kotios et al., 2022). Selline tehingutasandil kategoriseerimine on skaleeritav ja mugav, kuid jätab kasutaja ilma teabest, mida ta vajaks eelarve täpsemaks haldamiseks. Probleem on eriti märgatav just supermarketites, kus ostukorv on sageli segasisuga.

Eesti kontekstis on see probleem omandanud konkreetse praktilise mõõtme. Eesti jaemüüjad kasutavad kviitungitel eestikeelseid tootenimetusi, mis on sageli lühendatud ja kodeeritud. Kaupluste lojaalsusprogrammid, näiteks Maxima AITÄH portaal, pakuvad kasutajatele elektroonilisi kassatšekke (Maxima Eesti, s.a.), kuid need on mõeldud ostuajaloo vaatamiseks, mitte kulude kategoriseerimiseks. Pangad, näiteks Swedbank, pakuvad eelarve funktsioone tehingutasandil (Swedbank, s.a.), kuid ei kasuta kassatšeki kaubaridu kulude täpsustamiseks. Seega eksisteerivad Eestis juba nii digitaalsed kviitungid kui ka pangapõhised eelarvevahendid, kuid nende vahel puudub praktiline sild kaubaridade tasandil — olemasolevaid andmeallikaid ei ole omavahel ühendatud viisil, mis võimaldaks kulusid kategoriseerida tšeki sisu, mitte ainult müügikoha alusel.

Avalikult kättesaadavate allikate põhjal ei leitud käesoleva töö koostamisel avalikult kirjeldatud Eesti-spetsiifilist lahendust, mis ühendaks jaemüüja kassatšeki kaubaread, lokaliseeritud kategoriseerimise ja võrdluse pangatehingu tasandi kategooriaga. Rahvusvahelised PFM-rakendused, näiteks Toshl (Toshl, s.a.) ja YNAB (YNAB, s.a.), pakuvad pangaühendusi ja mõnikord kviitungite sisestamise võimalust, kuid eestikeelsete

kviitungite automaatset kaubaridade eraldamist ja kategoriseerimist nende raames ei ole kirjeldatud. See lünk annab käesolevale tööle praktilise aluse: uurida, kas ja kuivõrd on selline lähenemine Eesti tingimustes teostatav.

Üks viis kategoriseerimise täpsuse suurendamiseks on kasutada teavet kassatšeki üksikute kaubaridade tasandil. Kui süsteem eraldab kassatšekilt iga toote nimetuse ja hinna ning klassifitseerib need eraldi kategooriatesse, saab ühe ostu kulud jaotada mitme kategooria vahel. Sarnaseid lahendusi on käsitletud eelarve mobiilirakendustes, kus kviitungi tuvastamine vähendab käsitsi sisestamise mahtu (Garcia & Claour, 2021; Wong & Tan, 2024). Käesoleva töö prototüüp tugineb Maxima elektroonilistele kassatšekkidele, mis on saadaval tekstipõhiste PDF-failidena ja võimaldavad kaubaridade automaatset eraldamist ilma optilise märgituvastuseta. Pildipõhiste kviitungite töötlemine jääb käesoleva töö raamidest välja ja on käsitletud edasiste arendussammudena.

Töö eesmärk on arendada ja hinnata Eesti tingimustele lokaliseeritud prototüüpi, mis kategoriseerib supermarketi kulud kassatšeki kaubaridade alusel, ning määrata kindlaks, kuivõrd see lähenemine on praktiliselt rakendatav võrreldes pangatehingu tasandi baasjoone kategooriaga.

Eesmärgi saavutamiseks on vaja vastata järgmistele uurimisküsimustele:

1. Millised piirangud esinevad tehingutasandi kategoriseerimisel Eesti supermarketite ostude puhul ja kui suur osa kuludest jääb baasjoone meetodil liiga üldiselt jaotatud?
2. Kas kassatšeki kaubaridade eraldamine ja reeglistikupõhine kategoriseerimine on Eesti kaupluse kviitungite puhul automatiseeritav ning milline on saavutatav klassifikaatori kvaliteet?
3. Millised on sellise lähenemise peamised praktilised piirangud ja milliseid edasisi arendussamme on vaja süsteemi laiendamiseks?

Tegemist on rakendusliku pilootuuringuga. Töö andmestik (114 Maxima kassatšekki, 686 kaubarea põhjal) peegeldab ühe kasutaja ostuharjumusi ühe jaeketi piires üheksa kuu jooksul ega ole representatiivne Eesti elanikkonna ostuharjumuste suhtes. Pilootuuringu eesmärk on hinnata prototüübi teostatavust ja lähenemise potentsiaali, mitte anda üldistusi tarbijakäitumise kohta.

Töös kasutatud andmed on autori isiklikud ostuandmed. Toorfailid (kassatšekid ja pangaväljavõte) sisaldavad isikuandmeid, mistõttu neid käesolevas töös ei avaldata. Analüüsi tulemused on esitatud agregeeritud ja anonümiseeritud kujul.

Töö koosneb kahest põhipeatükist. Esimeses peatükis antakse teoreetiline ülevaade isikliku finantsjuhtimise kulude kategoriseerimise lähenemisviisidest, tehingutasandi meetodi piirangutest, kviitungitelt andmete eraldamise võimalustest ning Eesti konteksti eripäradest. Teises peatükis kirjeldatakse empiirilist osa: prototüübi ülesehitust ja arhitektuuri, andmete kogumise ja töötlemise metoodikat, pilootuuringu tulemusi ning klassifikaatori formaalset hindamist. Kokkuvõttes esitatakse peamised tulemused ja järeldused ning hinnatakse eesmärgi saavutamist.

1. TEOREETILINE ÜLEVAADE

1.1. Isiklik finantsjuhtimine ja kulude jälgimine

Isiklik finantsjuhtimine (Personal Financial Management, PFM) on praktiline raamistik, mis hõlmab sissetulekute ja kulude planeerimist, jälgimist ja analüüsimist eesmärgiga teha teadlikumaid rahalisi otsuseid. PFM-lähenemise raames saab kasutaja mitte lihtsalt tehingute loetelu, vaid struktureeritud ülevaate oma kulutuste mustrist: millised kululiigid moodustavad suurima osa, millised kulutused korduvad ja kus tekivad ülekulud (Struwig & Plaatjes, 2013).

Üks PFM-i keskseid funktsioone on kulude kategoriseerimine, kuna just see muudab üksikud tehingud kasutajale arusaadavateks rühmadeks. Ilma kategoriseerimiseta on kasutajal keeruline hinnata, kui palju ta kulutab toidule, transpordile, majapidamisele või muudele vajadustele. Struwig ja Plaatjes (2013) rõhutavad, et finantsjuhtimise vahendite praktiline väärtus sõltub sellest, kui hästi need aitavad kasutajal oma kulusid mõista ja kontrollida. Kui kategoriseerimine on ebatäpne või nõuab pidevat käsitsi korrigeerimist, väheneb vahendi kasutatavus ja kasutaja võib loobuda selle regulaarsest kasutamisest.

Kategoriseerimise täpsus on seejuures oluline mitte ainult mugavuse, vaid ka otsuste kvaliteedi seisukohast. Kui kategooriad on liiga üldised, näeb kasutaja moonutatud kulustruktuuri ja võib teha eelarveotsuseid vale info põhjal — näiteks alahinnata majapidamiskulusid, kuna need on peidetud toidukulude alla. Bitrián et al. (2021) uurisid

PFM-rakenduste kasutajate kaasatust ja leidsid, et kulude jälgimise, eelarvete ja kategooriapõhiste ülevaadete funktsioonid on peamised tegurid, mis motiveerivad kasutajaid finantsjuhtimise rakendustega regulaarselt tegelema. Seega mõjutab kategooriate kvaliteet otseselt PFM-vahendi kasutatavust ja kasutaja pikaajalist huvitatust oma rahaasjade haldamise vastu.

Eurostati leibkondade eelarve uuringu andmete kohaselt moodustavad eluasemekulud, toidukaubad ja transport suurima osa Euroopa Liidu leibkondade tarbimiskuludest (Eurostat, 2025). Toidukaubad ja alkoholivabad joogid moodustavad keskmiselt 16,9% kogukuludest. Need on kategooriad, mida kasutaja tavaliselt soovib jälgida, kuid mille täpne eristamine sõltub sellest, millisel detailsusastmel kategoriseerimine toimub.

Käesolevas töös käsitletakse PFM-i rakendusliku kontekstina, kus kategooriate täpsus mõjutab otseselt analüüsi kvaliteeti. Kui supermarketi ostu kulude jaotus ei vasta tegelikkusele, on ka sellel põhinevad järeldused moonutatud. Seetõttu on kategoriseerimise parandamine oluline osa PFM-vahendite praktilisest arendamisest.

1.2. Tehingutasandi kategoriseerimise piirangud

Pangandussüsteemides ja PFM-rakendustes on kõige levinum lähenemisviis tehingutasandil kategoriseerimine. Sellisel juhul kasutab süsteem tehingu tunnuseid: müügikohta, makse kirjeldust, summat ja mõnikord MCC-d (Merchant Category Code) või panga sisemist kategooriat. MCC on rahvusvaheline kood, mis peegeldab müügikoha tüüpi ja mille alusel pangad saavad tehingud automaatselt kategooriatesse jaotada. Selline lähenemine on skaleeritav ja ei vaja juurdepääsu ostu detailidele, mistõttu see töötab enamiku kasutajate jaoks kohe pärast pangaväljavõtte ühendamist (Kotios et al., 2022).

Tehingupõhise lähenemise skaleeritavust kinnitavad ka tööstuspraktikad. Lesner et al. (2019) kirjeldavad Intuit QuickBooks'i kategoriseerimissüsteemi, mis töötleb miljardeid finantstehinguid aastas ja kasutab selleks tehingu kirjelduse, summa ja konteksti kombinatsiooni. Autorid toovad esile, et isegi suuremahulised süsteemid peavad tegelema lühendatud ja mitmetähenduslike tehingukirjeldustega, mis muudab kategoriseerimise keeruliseks. See rõhutab, et tehingupõhine kategoriseerimine on küll laialdaselt kasutatav, kuid mitte probleemivaba isegi kõige arenenumate süsteemide puhul.

Tehingupõhisel lähenemisviisil on aga põhimõtteline piirang: see ei kajasta ostu koostist. Mitmesuguseid tooteid müüvate kaupluste puhul võib üks tehing hõlmata mitme kategooria tooteid, kuid süsteem näeb ainult kogusummat ja müügikoha tunnust. Selle tulemusena tekib süstemaatiline viga: kulud ühendatakse ühte kategooriasse sõltumata ostu tegelikust sisust. Kotios et al. (2022) kirjeldavad, kuidas pangandussüsteemides klassifitseeritakse tehingud automaatselt kliendi tehinguajaloo ja müügikoha tunnuste põhjal, kuid tunnistavad, et selline meetod on piiratud ega kajasta üksiku tehingu sisu.

See probleem on eriti märgatav supermarketite puhul, kus ostukorv on sageli segasisuga. Ühe ostu jooksul võib kasutaja osta toidukaupu, kodukeemiat, alkoholi ja majapidamistarvikuid, kuid pangatehingus kajastub see ühe summana kategoorias „Toidupoed" või „Supermarket". Baasjoone meetodina on selline lähenemine praktiline ja laialt kasutatav, kuid annab kasutajale ebatäpse pildi: osa kuludest, mis tegelikult ei ole toidukulud, liigitub toidukulude alla ja moonutab kulustruktuuri.

Detailne lähenemisviis eeldab, et süsteem töötab kassatšeki positsioonide ehk kaubaridade tasandil ja klassifitseerib iga rea eraldi. Sellisel juhul saab ühe ostu kulud jaotada mitme kategooria vahel ja kulude lõplik struktuur läheneb tegelikkusele. Selle lähenemise eelduseks on aga ligipääs kassatšeki andmetele ja suutlikkus neist kaubaridu eraldada ning struktureerida (Garcia & Claour, 2021; Wong & Tan, 2024).

1.3. E-kviitungid, PDF-dokumendid ja optiline märgituvastus

Kaubaridade tasandil kategoriseerimiseks peab süsteem saama kassatšekilt nimekirja toodete nimetuste ja hindadega. Kassatšekkide digitaalne kättesaadavus sõltub kaupluse ja riigi praktikast ning võib esineda mitmel kujul.

Esimene levinud vorm on tekstipõhine PDF-fail, mis sisaldab tekstikihti (text layer). Sellisest failist saab teksti otse ekstraheerida programmiliste vahenditega ilma optilise märgituvastuseta. Tekst on masinloetav ja selle eraldamine on usaldusväärsem, kuna ei sõltu pildi kvaliteedist ega tähemärkide tuvastamise täpsusest. Käesoleva töö prototüübi peamine andmeallikas — Maxima AITÄH portaali elektroonilised kassatšekid (Maxima Eesti, s.a.) — kuulub sellesse kategooriasse.

Teine levinud vorm on pildipõhine kviitung: skaneeritud paberkandjal tšekk, foto kassatšekist või mobiilirakenduse ekraanipilt. Sellisest failist andmete eraldamiseks on vaja

optilise märgituvastuse (Optical Character Recognition, OCR) tehnoloogiat, mis teisendab pildil olevad tähemärgid masinloetavaks tekstiks. OCR-põhine lähenemine on universaalsem, kuna see ei eelda konkreetset failivormingut, kuid on ka vigaderohkem: tuvastamise täpsus sõltub pildi kvaliteedist, valgustusest, fondi tüübist ja dokumendi struktuurist (Garcia & Claour, 2021).

Kviitungitelt andmete eraldamise keerukust illustreerib ICDAR 2019 rahvusvaheline võistlus (Scanned Receipts OCR and Information Extraction), kus osalesid mitmete riikide uurimisrühmad. Huang et al. (2019) kirjeldavad selle võistluse raames koostatud andmestikku ja tulemusi: isegi parimad süsteemid ei saavutanud täiuslikku täpsust, kuna kviitungite paigutus, fondid ja struktuur on väga varieeruvad. See kinnitab, et kviitungitelt andmete eraldamine on mittetriviaalne ülesanne, mis nõuab konkreetsele dokumendivormingule kohandatud lahendust.

Kviitungite puhul on oluline mitte ainult üksikute tähemärkide tuvastamine, vaid ka dokumendi struktuuri taastamine: kaubaridade nimekirja eraldamine pealkirjadest, kokkuvõtvatest ridadest, allahindlustest ja muudest elementidest. Garcia ja Claour (2021) kirjeldavad mobiilirakendust, kus kviitungi skaneerimise kaudu eraldatakse kulud automaatselt, vähendades käsitsi sisestamise mahtu ja kasutaja vigade riski. Wong ja Tan (2024) näitavad sarnaselt, et kviitungitelt andmete väljavõtmine on eelarve rakenduste tõhus komponent, kuigi tunnustamise ja struktureerimise kvaliteet sõltub konkreetsest dokumendivormingust.

Käesolevas töös kasutatakse tekstipõhist PDF-eraldamist, kuna Maxima elektroonilised kassatšekid sisaldavad tekstikihti. See on teadlik piiritlemine: tekstikihi olemasolu tagab usaldusväärsema andmeeraldamise kui OCR-põhine lähenemine ja võimaldab keskenduda kategoriseerimise kvaliteedi hindamisele, mitte märgituvastuse probleemidele. Pildipõhiste kviitungite töötlemine on käesoleva töö edasiste arendussammude hulgas.

1.4. Kulude kategoriseerimise lähenemised ja reeglistikupõhine klassifitseerimine

Kulude automaatne kategoriseerimine võib tugineda erinevatele lähenemisviisidele, mida saab laias laastus jagada kaheks: reeglistikupõhised ja masinõppepõhised meetodid.

Reeglistikupõhine (rule-based) klassifitseerimine kasutab eelnevalt koostatud reegleid, mis seostavad sisendteksti konkreetse kategooriaga. Tüüpiliselt koosneb selline süsteem

märksõnade sõnastikust: iga kategooria jaoks on defineeritud märksõnade loetelu ja sisendteksti sobitamisel sõnastikuga määratakse kategooria esimese vaste alusel. Reeglistikupõhise lähenemise eelised on läbipaistvus, kontrollitavus ja lihtsus: iga kategoriseerimise otsus on jälgitav ja seletatav, süsteem ei vaja treeningandmeid ja seda saab kohandada konkreetse keele ning domeeni jaoks. Peamised puudused on sõltuvus sõnastiku ulatusest ja käsitsi haldamise vajadus: kui sõnastikus puudub märksõna, jääb kaubarida tuvastamata, ja uute tootenimetuste lisandumisel tuleb sõnastikku täiendada (Aishwarya & Hemalatha, 2023).

Masinõppepõhine (machine learning-based) klassifitseerimine tugineb treeningandmetele, mille põhjal mudel õpib sisendteksti ja kategooria vahelisi seoseid. Masinõppel põhinevad mudelid on paindlikumad ja suudavad tuvastada ka keerulisemaid mustreid, mida reeglistikuga on raske katta. Kotios et al. (2022) kirjeldavad süvaõppepõhist lähenemist pangatehingute klassifitseerimiseks, kus mudel õpib tehingu kirjelduse ja kategooria vahelisi seoseid suurte andmehulkade põhjal. García-Méndez et al. (2020) rakendavad tugivektormasinat (SVM) pangatehingute lühitekstide klassifitseerimiseks 15 kulukategooriasse, kasutades spetsialiseeritud märgendatud korpust. Autorid rõhutavad, et finantstekstide lühidus ja lühendatus nõuab spetsiifilisi eeltöötlusmeetodeid, mis on otseselt võrreldav kviitungi kaubaridade klassifitseerimise ülesandega. Samas nõuavad sellised masinõppepõhised lähenemised märkimisväärset treeningandmete kogust, on vähem läbipaistevad ja raskemini kohandatavad konkreetse keele- ja domeenikontekstiga.

Aishwarya ja Hemalatha (2023) käsitlevad kulude jälgimise süsteemi, kus masinõpet kasutatakse kulude automaatseks klassifitseerimiseks. Autorid rõhutavad, et klassifitseerimise kvaliteet sõltub andmete korrektsest ettevalmistamisest ja tunnuste mõistlikust valikust, mis on eriti oluline kviitungite tekstiga töötamisel, kus tootenimetused on sageli lühendatud ja mitmetähenduslikud.

Käesoleva töö prototüübis on kasutatud reeglistikupõhist lähenemist. See valik on põhjendatud mitme kaalutlusega, mis on otseselt seotud töö praktilise kontekstiga. Esiteks, eestikeelsete kviitungite kontekstis on sõnastiku koostamine otsesem viis lokaliseeritud klassifikaatori loomiseks, kuna eestikeelseid märgendatud treeningandmestikke kassatšekkide kategoriseerimiseks avalikult ei ole — erinevalt García-Méndez et al. (2020) ja Kotios et al. (2022) käsitletud inglise- ja hispaaniakeelsetest andmestiketest. Teiseks, reeglistikupõhine klassifikaator on läbipaistev: kasutaja näeb, milline reegel igale kaubareale

rakendus, ja saab vajadusel tulemust käsitsi parandada — see toetab PFM-rakenduse kasutatavust, kus kasutaja usaldus sõltub süsteemi seletatavusest. Kolmandaks, bakalaureuse tasandil pilootuuringu jaoks on reeglistikupõhine lähenemine praktiliselt realiseeritav ilma suurte treeningandmestikega. Klassifikaatori piirangutest ja kvaliteedist antakse ülevaade empiirilises osas.

1.5. COICOP-il põhinev lihtsustatud kategooriastik

Kulude kategoriseerimiseks on vaja kategooriastikku, mille järgi kaubaread liigitada. Käesolevas töös tuginetakse COICOP-klassifikatsioonile (Classification of Individual Consumption According to Purpose), mille on välja töötanud Ühinenud Rahvaste Organisatsioon ja mida kasutatakse laialdaselt tarbimiskulude statistikas, sealhulgas Eurostati leibkondade eelarve uuringutes (United Nations, 2018; Eurostat, 2025).

COICOP-klassifikatsioon jaotab tarbimiskulud hierarhiliselt 14 põhirühma, mis omakorda jagunevad alarühmadeks. Põhirühmad hõlmavad näiteks toidukaupu ja alkoholivabu jooke (jaotis 01), alkoholi ja tubakat (jaotis 02), riietust ja jalanõusid (jaotis 03), eluaset (jaotis 04), sisustust ja majapidamiskaupu (jaotis 05) ja nii edasi. Täismahulise COICOP-klassifikatsiooni kasutamine pilootuuringus oleks ebaotstarbekas, kuna supermarketi sortiment katab ainult osa COICOP-jaotistest ja mitmete kategooriate eristamine üksnes kviitungi tootenimetuse põhjal ei ole alati võimalik.

Seetõttu piiritleti käesolevas töös lihtsustatud kategooriastik viie põhikategooria ja ühe lisakategooriaga, mis katavad Eesti supermarketite tüüpilise sortimendi: (1) toidukaubad ja alkoholivabad joogid (COICOP 01), (2) alkohol ja tubakas (COICOP 02), (3) majapidamis- ja puhastusvahendid (COICOP 05 osa), (4) majapidamistehnika (COICOP 05 osa), (5) lilled ja kingitused (COICOP 09/12 osa), (6) muu. See lihtsustatud kategooriastik võimaldab näidata tehingupõhise meetodi piiranguid konkreetsetes kategooriates, jäädes samas hallatavaks reeglistiku koostamise ja käsitsi märgendamise jaoks. COICOP-ga sidumine tagab, et kategooriad on rahvusvaheliselt võrreldavad ja põhinevad tunnustatud statistilisel raamistikul, mitte ad hoc jaotustel.

1.6. Eesti kontekst ja kohalike andmete eripära

Süsteemi lokaliseerimine on oluline, kuna andmete eraldamise ja kategoriseerimise kvaliteet sõltub keelest, tootenimetuste kirjutamise tavadest ja kviitungite vormingutest. Eestis on

kassatšekkide tootenimetused reeglina esitatud eesti keeles ja sageli lühendatud: kasutatakse lühendeid, kaubamärgi koode ja sisemisi artiklinumbreid, mis ei ole ilma kontekstita üheselt mõistetavad. Näiteks võib kviitung sisaldada lühendeid nagu „S/R MAX K/R HAPUKOOR" (Maxima kaubamärgi hapukoor) või „JOOG LIMPA CLASSIC" (limonaad). See mõjutab nii teksti normaliseerimise etappi kui ka järgnevat kategoriseerimist, kuna klassifikaator peab arvestama kohalikke lühendeid ja nimetuste eripärasid.

Eesti jaemüügi kontekstis on oluline ka kassatšekkide kättesaadavus digitaalsel kujul. Erinevatel kauplustel on erinevad praktikad. Käesoleva töö raames kasutati Maxima AITÄH lojaalsusprogrammi (Maxima Eesti, s.a.), mis pakub kasutajatele elektroonilisi kassatšekke PDF-kujul tekstikihiga. Käesoleva töö raames ei leitud teist samaväärset avalikult kasutatavat iseteeninduslahendust, mis võimaldaks kassatšekke programmiliselt alla laadida. See piirab süsteemi laiendatavust ja on üks käesoleva töö praktilistest piirangutest.

Uuringud kviitungitelt andmete eraldamise kohta on näidanud, et tulemuse kvaliteet sõltub sellest, kui hästi tunnustamisvahend ja parsimisloogika sobivad konkreetse dokumendivormingu ja keelega (Garcia & Claour, 2021; Wong & Tan, 2024). Seetõttu tuleb Eesti-keskse projekti puhul arvesse võtta kohaliku jaemüügi ja kviitungite teksti eripärasid, et süsteem annaks stabiilse tulemuse. Üldotstarbeline mitmekeelne lahendus ei pruugi eestikeelsete kviitungite puhul anda sama kvaliteeti kui lokaliseeritud sõnastik ja parsimisreeglid, mis on koostatud konkreetse kaupluse kviitungite alusel.

Teoreetilise ülevaate põhjal kirjeldatakse järgmises peatükis prototüübi ülesehitust, andmete töötlemise protsessi ning pilootuuringu tulemusi.

2. EMPIIRILINE OSA

2.1. Metoodika

Käesolevas töös kasutatakse rakendusliku pilootuuringu lähenemisviisi, mille eesmärk on hinnata kaubaridade põhise kulukategoriseerimise praktilist teostatavust ja täpsust Eesti kontekstis. Uurimisdisain koosneb kahest omavahel seotud osast: (1) prototüübi arendamine, mis automatiseerib andmete kogumise ja töötlemise ahela, ning (2) pilootuuring, milles võrreldakse kaubaridade meetodit tehingupõhise baasjoone meetodiga reaalandmete põhjal.

Pilootuuringus võrreldakse kahte kulude kategoriseerimise meetodit. Esimene on baasjoone meetod, kus Swedbanki internetipanga kasutajaliides määrab käesolevas andmestikus enamikule supermarketi tehingutest kategooria „Toidupoed", mistõttu kogu ostusumma läheb ühte rühma sõltumata tegelikust ostusisust. Teine on kaubaridade meetod, kus kassatšekilt eraldatakse iga kaubarida eraldi ja liigitatakse COICOP-il põhinevasse lihtsustatud kulukategooriasse.

Baasjoone valik vajab täpsustamist. Swedbanki pangaväljavõtte CSV-eksport ei sisalda kategooria veergu, mistõttu baasjoone kategooriat ei ole võimalik otse failist lugeda. Selle asemel fikseeriti baasjoone kategooria „Toidupoed" Swedbanki internetipanga tehingu detailvaatest enne kasutajapoolset käsitsi muutmist. Selline lähenemine peegeldab olukorda, mille kasutaja näeb vaikimisi: pank liigitab supermarketi tehingu müügikoha tunnuste alusel ühte kategooriasse, eristamata ostu tegelikku sisu.

Kategoriseerimiseks kasutati COICOP-il (Classification of Individual Consumption According to Purpose) põhinevat kohandatud lihtsustatud kategooriastikku. Täismahulise COICOP-klassifikatsiooni asemel piiritleti pilootuuringu tarbeks viis põhikategooriat ja üks lisakategooria, mis katavad Eesti supermarketite tüüpilise sortimendi:

1. Toidukaubad ja alkoholivabad joogid — vastab COICOP jaotisele 01.
2. Alkohol ja tubakas — vastab COICOP jaotisele 02.
3. Majapidamis- ja puhastusvahendid — vastab COICOP jaotise 05 osale (mittekestvad majapidamiskaubad).
4. Majapidamistehnika — vastab COICOP jaotise 05 osale (kestvad kaubad).
5. Lilled ja kingitused — vastab COICOP jaotise 09/12 osale.
6. Muu — sisaldab ridu, mis ei kuulu ühtegi eelnevasse kategooriasse, kuid mille puhul sõnastiku reegel siiski rakendub (nt tagasimaksed ja tagastused). Need read klassifitseeritakse kategooriasse „Muu" konkreetse märksõnareegli alusel (category_source = rule_match), mitte kui tuvastamata read.

Lihtsustatud kategooriastiku valik on põhjendatud pilootuuringu praktiliste kaalutlustega: viis põhikategooriat on piisav, et näidata tehingupõhise meetodi piiranguid supermarketite kontekstis, kuid samas hallatav reeglistiku koostamise ja tulemuste kontrollimise jaoks.

Pakendidepositid (metallpurk, PET-pudel, pandipakend jt) tuvastatakse eraldi ja märgistatakse depositidena — neid ei arvestata tarbimiskuludes, kuna tegemist on tagastatava tagatisrahaga, mis ei kujuta endast reaalset tarbimiskulutust.

Klassifikaator töötab reeglistikupõhiselt ja igale kaubareale omistatakse lisaks kategooriale ka kategooria allikas (category_source), mis näitab, kuidas kategooria määrati:

- rule_match — kaubareal leiti sõnastiku märksõnavaste ja kategooria määrati selle alusel. See hõlmab ka kategooria „Muu" ridu (nt tagasimaksed), mille jaoks on eraldi märksõnareeglid;

- fallback_food — kaubarida on normaalne tooterida, kuid ühegi spetsiifilise reegli märksõna ei sobinud. Sellised read klassifitseeritakse jääkkategooriana kategooriasse „Toidukaubad ja alkoholivabad joogid", lähtudes eeldusest, et enamik supermarketi kaubaridadest on toidukaubad. Tegemist ei ole kinnitatud klassifikatsiooniga, vaid vaikimisi omistamisega reegli puudumisel;

- deposit — rida tuvastati pakendidepositina ja jäeti tarbimiskulude arvutusest välja;

- unknown — rida on parseri müra, poolik rida või liiga vähese infosisaldusega, et seda üheselt kategoriseerida. Käesolevas andmestikus selliseid ridu ei esinenud (0 rida).

Klassifikaatori kvaliteedi hindamiseks koostati käsitsi märgendatud kuldstandard 200 kaubarea põhjal. Hindamisel võrreldi klassifikaatori väljundit kuldstandardiga ja arvutati täpsus (accuracy), makro-F1 skoor ning koostati segiajamistabel (confusion matrix).

Andmekaitseeetika. Kõik kasutatud andmed on töö autori isiklikud ostuandmed. Kassatšekkides ja pangaväljavõttes sisalduvaid isikuandmeid (kaardinumber, e-post) käesolevas töös ei avaldata. Analüüsis kasutatakse ainult agregeeritud näitajaid ja anonümiseeritud kassatšekkide ID-sid. Kuna uuritakse ainult autori enda andmeid, ei ole kolmandate isikute nõusolekut vaja.

2.2. Prototüübi kirjeldus

2.2.1. Ülesehitus ja arhitektuur

Käesoleva töö raames töötati välja prototüüp, mis automatiseerib kulude kategoriseerimise protsessi kassatšekkide põhjal. Käesoleva prototüübi raames toetati Maxima kaupluseketti,

mille AITÄH lojaalsusprogramm pakub elektroonilisi kassatšekke tekstipõhiste PDF-failidena. Prototüübi peamine eesmärk on näidata, et kaubaridade lähenemine on tehniliselt teostatav ja annab kasutajale täpsema kulustruktuuri kui tehingupõhine baasjoone meetod.

Prototüüp koosneb kolmest põhikihist.

Esimene kiht on kviitungite allalaadimine, mis on realiseeritud Node.js-is koos brauseri automatiseerimise teegiga Playwright. See moodul suhtleb Maxima iseteenindusportaaliga ja laadib alla kassatšekid PDF-kujul.

Teine kiht on andmete töötlemise ahel (pipeline), mis on realiseeritud Pythonis ja koosneb neljast järjestikusest sammust: (a) kviitungite parsimine (parse_receipts), (b) kaubaridade kategoriseerimine (categorize), (c) kviitungite seostamine pangaväljavõttega (match_bank) ja (d) koondaruande genereerimine (report).

Kolmas kiht on töölauarakendus, mis on realiseeritud Electron-raamistikus ja pakub graafilist kasutajaliidest eelpool nimetatud moodulite käivitamiseks ning tulemuste ülevaatamiseks.

2.2.2. Kviitungite allalaadimine

Maxima Eesti pakub kasutajatele elektroonilisi kassatšekke läbi lojaalsusprogrammi AITÄH portaali (https://aitah.maxima.ee). Prototüübi esimene moodul automatiseerib kassatšekkide allalaadimise valitud ajavahemiku eest.

Kasutaja käivitab skripti käsurealt, määrates allalaadimise perioodi (parameetrid --from ja --to) ning väljundkausta. Autentimine toimub Smart-ID kaudu: kuna Smart-ID autentimist ei ole võimalik täielikult automatiseerida, avab skript nähtava brauseriakna, kus kasutaja kinnitab sisselogimise käsitsi. Pärast edukat sisselogimist salvestatakse seansiandmed (küpsised) lokaalselt, et järgnevad käivitused ei nõuaks uut autentimist. Kasutaja saab seansiandmed igal ajal kustutada.

Allalaadimismoodul loeb portaali tabelit „Minu ostud", toetab lehekülgede vahetamist ja laadib iga ostu kassatšeki alla PDF-failina. Failid salvestatakse struktureeritud kaustadesse (receipts/Maxima/YYYY-MM/) ning moodustatakse kokkuvõttev CSV-fail (purchases.csv) allalaaditud ostude nimekirjaga, mis võimaldab hiljem piirata analüüsi ainult konkreetse allalaadimissessiooni failidega.

2.2.3. Kviitungite parsimine

Maxima elektroonilised kassatšekid on tekstipõhised PDF-failid, millest saab teksti otse ekstraheerida ilma optilise märgituvastuseta, kasutades Pythoni teeki pypdf. Tekstikihi olemasolu on oluline tehniline eeldus, mis tagab täpse ja usaldusväärse andmete eraldamise.

Parsimisloogika toimib järgmiselt. Iga kaubarea tuvastatakse regulaaravaldiste abil: otsitakse ridu, mis sisaldavad toote nimetust, kogust ja hinda. Kuna Maxima kviitungitel võivad pikad tootenimetused ulatuda üle mitme rea, liidetakse sellised read üheks kirjeks. Allahindlused seostatakse vahetult eelneva tootega ja lahutatakse bruto hinnast, andes neto hinna, mida kasutatakse edaspidises analüüsis. Pakendidepositid tuvastatakse eraldi tunnuste abil (tüüpilised nimetused nagu „Metallpurk (Al)", „Pet pudel" jt) ja märgistatakse depositidena.

Parsimise tulemus salvestatakse kahte CSV-faili: items_raw.csv (kõik tuvastatud kaubaread koos toornäitajatega) ja receipts.csv (kassatšekkide koondandmed).

2.2.4. Kategoriseerimine

Kategoriseerimine toimub reeglistikupõhiselt. Iga kaubarida võrreldakse eestikeelsete märksõnade sõnastikuga, mis on jaotatud kuude eelpool kirjeldatud kategooriasse. Klassifikaator kasutab alamstringi sobitamist: iga reegli jaoks on defineeritud märksõnade loetelu ja esimene leitud vaste määrab kategooria.

Näiteks: märksõna „ZEWA" või „WC-PAB" viitab majapidamis- ja puhastusvahendite kategooriale; „KRÜSANTEEM" või „ROOSID" viitab lillede kategooriale; „VIIN" või „SIIDER" viitab alkoholi kategooriale. Kui ükski reegel ei sobi, määratakse kaubareal jääkkategooriana „Toidukaubad ja alkoholivabad joogid" (fallback_food) — see tähendab, et rida on normaalne supermarketi tooterida, kuid spetsiifiline reegel ei rakendu, ning toidukategooria omistatakse vaikimisi kui kõige tõenäolisem variant.

Sõnastiku koostamisel tugineti pilootandmestiku kaubaridade nimetustele. Eesti kaupluste kviitungitel on tootenimetused sageli lühendatud ja kodeeritud (nt „JOOG LIMPA CLASSIC" tähendab limonaadi, „S/R MAX K/R HAPUKOOR" tähendab Maxima kaubamärgi hapukoort), mistõttu sõnastik sisaldab nii täisnimetusi kui ka tüüpilisi lühendeid.

Kategoriseerimise tulemus salvestatakse faili items_categorized.csv, kuhu lisatakse kolm veergu: category (määratud kategooria), category_rule (sobitatava reegli märksõna) ja

category_source (kategooria määramise viis: rule_match, fallback_food, deposit või unknown).

2.2.5. Seostamine pangaväljavõttega

Kviitungite seostamine pangaväljavõttega (matching) on vajalik selleks, et siduda kassatšekilt saadud detailne kulustruktuur pangatehinguga ja võrrelda kaubaridade meetodit baasjoone meetodiga.

Seostamisel kasutatakse kolme tunnust koos: (a) kassatšeki kogusumma peab vastama pangatehingu summale tolerantsiga ±0,01 eurot; (b) müügikoha nimi tuvastatakse pangaväljavõtte väljal „Saaja/Maksja" märksõnade sobitamise teel (nt „MAXIMA" → Maxima); (c) kassatšeki kuupäev peab jääma pangatehingu kuupäevast ±3 päeva piiresse, kuna kaarditehing ja panga töötluse kuupäev ei pruugi kokku langeda.

Seostamise tulemus salvestatakse faili matched.csv, kus iga rida sisaldab nii kassatšeki kui ka vastava pangatehingu andmeid.

2.2.6. Aruandlus ja kasutajaliides

Aruandlusmoodul (report) arvutab koondnäitajad: seostamise edukus, segasisuga kassatšekkide osakaal, baasjoone meetodist erinevate kaubaridade arv ja summa ning kulude jaotus kategooriate lõikes neto hindade alusel.

Prototüübi töölauarakendus (Electron) pakub graafilist kasutajaliidest, mis on jaotatud nelja vaatesse.

Esimene vaade (Data collection) võimaldab käivitada kviitungite allalaadimist ja analüüsi ning valida pangaväljavõtte CSV-faili. Vaade sisaldab kuupäevade piiritlemise funktsiooni ja logiaknaga, kus kuvatakse moodulite töö käik. Enne analüüsi käivitamist kontrollib rakendus, kas valitud pangaväljavõtte kuupäevad kattuvad allalaaditud kviitungite perioodiga, ja kuvab hoiatuse, kui kattumine on nõrk.

Teine vaade (Parsing review) kuvab kviitungitest eraldatud toorridu ning võimaldab neid filtreerida tüübi järgi (puhas kaubarida, müra, deposit), et kasutaja saaks kontrollida parsimise kvaliteeti.

Kolmas vaade (Categorization review) kuvab kategoriseeritud kaubaread koos rakendunud reegliga. Kasutaja saab selles vaates käsitsi parandada kategooriaid, mis salvestatakse eraldi faili (manual_corrections.csv) — see võimaldab kasutaja tagasisidet arvestada klassifikaatori parandamisel.

Neljas vaade (Baseline & reporting) kuvab koondnäitajad, graafilise kulude jaotuse (Chart.js) ja seostamistabeli. Vaade võimaldab ka uurimisaruande eksportimist.

Kasutajaliidese keel on vaikimisi eesti keel, kusjuures kasutajal on võimalik lülituda inglise keelele. Rakenduse sisemised logid kuvatakse alati inglise keeles.

2.3. Andmete kogumine ja töötlemine

Käesolevas töös kasutati Maxima AITÄH portaali andmeid. 114 elektroonilist kassatšekki laaditi alla prototüübi allalaadimismooduli abil PDF-kujul. Andmed pärinevad perioodist 02.07.2025–26.03.2026. Kõik kaubaread eraldati automaatselt prototüübi parsimismooduli abil.

Kokku tuvastati 761 rida, millest 75 rida (9,9%) olid pakendidepositid ja jäeti tarbimiskulude analüüsist välja. Analüüsitav andmestik koosneb seega 686 kaubareast.

Pangaväljavõte eksporditi Swedbanki internetipangast CSV-formaadis. Eksporditav fail sisaldab järgmisi välju: Kliendi konto, Reatüüp, Kuupäev, Saaja/Maksja, Selgitus, Summa, Valuuta, Deebet/Kreedit, Arhiveerimistunnus, Tehingu tüüp, Viitenumber ja Dokumendi number. Nagu eelpool mainitud, ei sisalda see eksport kategooria veergu, mistõttu baasjoone kategooria fikseeriti Swedbanki kasutajaliidese tehingu detailvaatest.

Iga kaubarida kategoriseeriti prototüübi reeglistikupõhise klassifikaatori abil. Kategooria allikate jaotus kogu andmestiku ulatuses (761 rida, sh depositid) on järgmine: rule_match — 593 rida (77,9%), fallback_food — 93 rida (12,2%), deposit — 75 rida (9,9%), unknown — 0 rida. Seega sai 77,9% ridadest kategooria konkreetse märksõnavaste alusel, 12,2% klassifitseeriti jääkkategooriana toidukaubaks reegli puudumisel ja 9,9% tuvastati depositidena. Kategooria „Muu" kaks rida (tagasimaksed) said oma kategooria samuti konkreetse märksõnareegli alusel (rule_match), mitte kui tuvastamata read.

Kaubarea neto hind arvutati kui bruto hind miinus konkreetsele tooteriale märgitud allahindlus. Pakendidepositid (kokku 7,50 EUR) jäeti tarbimiskuludest välja.

Seostamisel kviitungite ja pangaväljavõtte vahel kasutati eelpool kirjeldatud kolme tunnuse kombinatsiooni (summa, müügikoht, kuupäev). 108 kassatšekki 114-st seostati edukalt pangatehinguga (94,7%). Kuus kassatšekki jäid seostamata, kuna vastavad tehingud ei kuulunud eksporditud pangaväljavõtte perioodi.

Klassifikaatori kvaliteedi hindamiseks koostati eraldi kuldstandard: 200 kaubarida märgendati käsitsi õige kategooria ja võrreldi klassifikaatori väljundiga. Hindamisvalim ei sisaldanud deposit-ridu. Hindamisvalimi moodustamisel kasutati juhuslikkust, tagamaks, et valim katab erinevaid kategooriaid ja tootetüüpe.

2.4. Tulemused

2.4.1. Pilootuuringu koondtulemused

Pilootuuringus analüüsiti 114 kassatšekki ja 686 kaubareale (välja arvatud pakendidepositid). Tabelites 1 ja 2 esitatud andmed põhinevad prototüübi automaatsel reeglistikupõhisel kategoriseerimisel. Käsitsi märgendatud kuldstandardit kasutati ainult klassifikaatori kvaliteedi eraldi hindamiseks (alapeatükk 2.4.3). Põhinäitajad on esitatud tabelis 1.

Tabel 1. Pilootuuringu andmestiku kokkuvõte

Näitaja	Väärtus
Kassatšekkide arv	114
Pangaväljavõttega seostatud	108 / 114 (94,7%)
Kaubaread (v.a pakendidepositid)	686
Tasutud summa kokku	1821,18 EUR
Pakendidepositid (välistatud)	7,50 EUR
Tegelikud tarbimiskulud	1813,68 EUR
Segasisuga tšekid (≥ 2 kategooriat)	46 / 114 (40%)
Baseline'ist erinevad kaubaread	79 / 686 (11,5%)
Baseline'ist erinev summa	291,67 EUR (16,1%)

Allikas: autori koostatud.

46 kassatšekki 114-st (40%) on segasisuga — see tähendab, et ühe ostu jooksul ostetakse kaupu rohkem kui ühest kulukategooriast. Kuigi enamik kassatšekkidest sisaldab ainult toidukaupu, näitab nelja kümnendiku segasisuga tšekkide osakaal, et tehingutasandil kategoriseerimine on supermarketite puhul liiga üldine ega erista ostu tegelikku sisu märkimisväärse osa ostude puhul.

79 kaubarida 686-st (11,5%) kuulub teistesse kategooriatesse peale toidukaupu. Summades väljendatuna moodustab see 291,67 eurot ehk 16,1% tegelikest tarbimiskuludest (1813,68 EUR).

2.4.2. Kulude jaotus kategooriate lõikes

Kulude jaotus kategooriate lõikes kaubaridade meetodil on esitatud tabelis 2.

Tabel 2. Kulude jaotus kategooriate lõikes (kaubaridade meetod, neto hinnad)

Kulukategooria	Summa (EUR)	Osakaal	Kaubaridu
Toidukaubad ja alkoholivabad joogid	1522,01	83,9%	607
Majapidamis- ja puhastusvahendid	164,57	9,1%	47
Alkohol ja tubakas	85,16	4,7%	18
Majapidamistehnika	24,99	1,4%	1
Lilled ja kingitused	14,15	0,8%	11
Muu	2,80	0,2%	2
KOKKU	1813,68	100,0%	686

Allikas: autori koostatud. Märkus: summad on ümardatud sendini.

Toidukaubad moodustavad 83,9% tegelikest tarbimiskuludest. Ülejäänud 16,1% jaguneb viie kategooria vahel. Suurimad erinevused baasjoone meetodist tekivad majapidamis- ja puhastusvahendite (164,57 EUR, 9,1%) ning alkoholi ja tubaka (85,16 EUR, 4,7%) kategoorias. Neile järgnevad majapidamistehnika (24,99 EUR, 1,4%), lilled ja kingitused (14,15 EUR, 0,8%) ning muu (2,80 EUR, 0,2%).

2.4.3. Klassifikaatori kvaliteedi hindamine

Reeglistikupõhise klassifikaatori kvaliteeti hinnati eraldi käsitsi märgendatud kuldstandardi alusel. Hindamisvalim koosnes 200 kaubareast ja ei sisaldanud deposit-ridu. Tulemused on esitatud tabelis 3.

Tabel 3. Klassifikaatori hindamise koondtulemused

Mõõdik	Väärtus
Hindamisvalimi suurus	200 kaubarida
Üldtäpsus (accuracy)	0,87 (87%)
Makro-F1 skoor	0,78

Allikas: autori koostatud.

Üldtäpsus 87% näitab, et klassifikaator määrab enamikule kaubaridadest õige kategooria. Makro-F1 skoor 0,78 on mõnevõrra madalam, kuna see arvestab kõiki kategooriaid võrdselt, sõltumata nende esindatusest valimis, ja harvaesinevad kategooriad tõmbavad keskmist alla.

Klassipõhised tulemused on esitatud tabelis 4.

Tabel 4. Klassifikaatori täpsus kategooriate lõikes

Kategooria	Täpsus (P)	Saagis (R)	F1	Valimi suurus (n)
Toidukaubad ja alkoholivabad joogid	0,94	0,88	0,91	146
Alkohol ja tubakas	0,59	1,00	0,74	10
Majapidamis- ja puhastusvahendid	0,97	0,78	0,86	40
Majapidamistehnika	1,00	1,00	1,00	1
Lilled ja kingitused	0,09	1,00	0,17	1
Muu	1,00	1,00	1,00	2

Allikas: autori koostatud.

Kõige stabiilsemalt töötab klassifikaator toidukaupadega (F1 = 0,91) ja majapidamis- ning puhastusvahenditega (F1 = 0,86): need on kaks kõige sagedasemat kategooriat, mille jaoks sõnastik on kõige ulatuslikum. Alkoholi kategooria saagis on maksimaalne (R = 1,00) — kõik tegelikud alkoholitooted tuvastatakse õigesti —, kuid täpsus on madalam (P = 0,59), mis tähendab, et osa mittealkohoolsetest toodetest klassifitseeritakse ekslikult alkoholiks. Lillede ja kingituste kategooria täpsus on väga madal (P = 0,09): 10 toidukaupa 11-st, mille klassifikaator lillede kategooriasse liigitas, olid tegelikult toidukaubad.

Oluline on märkida, et kategooriate majapidamistehnika (n = 1), lilled ja kingitused (n = 1) ning muu (n = 2) hindamine on piiratud väikese valimi tõttu. Nende kategooriate tulemused ei ole statistiliselt usaldusväärsed ja neid tuleb tõlgendada ettevaatlikult.

Segiajamistabel on esitatud tabelis 5.

Tabel 5. Segiajamistabel (confusion matrix): tegelik kategooria (read) vs klassifikaatori ennustus (veerud)

Tegelik \ Ennustus	Toiduk.	Alkohol	Majap.vah.	Majap.tehn.	Lilled	Muu
Toidukaubad	129	6	1	0	10	0
Alkohol ja tubakas	0	10	0	0	0	0

Majap.vahendid	8	1	31	0	0	0
Majap.tehnika	0	0	0	1	0	0
Lilled ja king.	0	0	0	0	1	0
Muu	0	0	0	0	0	2

Allikas: autori koostatud. Märkus: diagonaalil on õigesti klassifitseeritud read; väljaspool diagonaali on vead.

Segiajamistabelist on näha kolm peamist veaallikat: 10 toidukaupa liigitati lillede kategooriasse (liiga laiad lillede reeglid), 8 majapidamiskaupa jäi tuvastamata ja liigitati toidukategooriasse (sõnastiku lüngad) ning 6 toidukaupa liigitati alkoholi kategooriasse (märksõnade mitmeti tõlgendatavus).

2.5. Arutelu, piirangud ja edasised sammud

2.5.1. Tulemuste tõlgendamine

Pilootuuringu tulemused kinnitavad, et kaubaridade lähenemine annab täpsema kulustruktuuri võrreldes tehingupõhise baasjoone meetodiga. 114 kassatšeki ja 686 kaubarea analüüs näitas, et 16,1% tarbimiskuludest (291,67 EUR) oleks baasjoone meetodil liigitatud toidukulude alla, kuigi need kuuluvad teistesse kategooriatesse. Üheksa kuu andmete põhjal on see summa võrreldav mitme kuu kodukeemia- ja puhastusvahendite kuludega, mis näitab, et erinevusel on praktiline tähtsus isikliku eelarve jälgimisel.

Need tulemused on kooskõlas teoreetilises osas kirjeldatud probleemiga, mille kohaselt tehingupõhine kategoriseerimine ei kajasta ostu koostist laia sortimendiga kaupluste puhul. Eurostati andmete kohaselt moodustavad toidukaubad ja alkoholivabad joogid Euroopa Liidu leibkondade tarbimiskuludest keskmiselt 16,9% (Eurostat, 2025), mis kinnitab, et tegemist on olulise kulukategooriaga, mille täpne jälgimine on põhjendatud.

2.5.2. Klassifikaatori hindamine

Reeglistikupõhine klassifikaator saavutas üldtäpsuse 87% ja makro-F1 skoori 0,78. See näitab, et lihtne märksõnapõhine lähenemine annab Maxima kviitungite kontekstis praktiliselt kasutatava tulemuse, kuigi sellel on selged piirangud.

Peamised nõrkused on seotud kolme probleemiga. Lillede ja kingituste kategooria reeglid on liiga laiad ning tekitavad valepositiivseid tulemusi toidukaupadega — see on klassifikaatori suurim üksikviga, mille parandamine eeldab reeglite kitsendamist. Osa

majapidamiskaupu jääb sõnastiku lünkade tõttu tuvastamata. Alkoholi kategooria märksõnad sobivad mõnikord ka mittealkohoolsete toodete nimetustega. Need tulemused viitavad sellele, et klassifikaatori kvaliteet sõltub otseselt sõnastiku ulatusest ja reeglite täpsusest ning sõnastiku täiendamine parandaks tulemusi ilma klassifikaatori arhitektuuri muutmata.

2.5.3. Prototüübi praktiline hindamine

Prototüüp näitab, et kviitungite allalaadimine, kaubaridade eraldamine ja kategoriseerimine on automatiseeritav Maxima kaupluste puhul, kus kassatšekid on saadaval tekstipõhise PDF-failina. Andmetöötlusahel (parse → categorize → match_bank → report) töötab järjestikku ja tulemused on reprodutseeritavad samade sisendandmetega. Kategoriseerimise tulemus on kontrollitav: kasutajaliideses on näha, milline reegel igale kaubareale rakendus, ja kasutaja saab käsitsi parandusi teha. Seostamine pangaväljavõttega andis pilootuuringus 94,7% edukuse (108/114).

2.5.4. Piirangud

Pilootuuringul on mitmeid piiranguid, mida tuleb tulemuste tõlgendamisel arvestada.

Andmestiku esindavus on piiratud. Valim (114 kassatšekki, 686 kaubareale) peegeldab ühe kasutaja ostuharjumusi ühe jaeketi piires üheksa kuu jooksul. Andmestik ei ole representatiivne Eesti elanikkonna ostuharjumuste suhtes ega pretendeeri selleks. Pilootuuringu eesmärk on hinnata prototüübi teostatavust ja meetodi potentsiaali, mitte anda üldistusi tarbijakäitumise kohta.

Kaupluse valik on piiratud. Käesoleva prototüübi raames toetati Maxima kauplusketti, kuna AITÄH portaal pakub kassatšekke tekstipõhiste PDF-failidena, mis võimaldab automatiseeritud andmete eraldamist. Teiste kaupluste lisamine eeldaks vastavate andmeallikate integreerimist.

Reeglistikupõhine klassifikaator sõltub sõnastiku ulatusest. Nagu klassifikaatori hindamine näitas, tekitavad liiga laiad reeglid valepositiivseid tulemusi ja liiga kitsad reeglid jätavad osa kaupu tuvastamata. Sõnastiku optimeerimine on pidev protsess, mis vajab regulaarset ülevaatamist uute tootenimetuste lisandumisel.

Hindamisvalimi struktuur kajastab andmestiku jaotust: 146 rida 200-st on toidukaubad, samas kui mõnes kategoorias (majapidamistehnika, lilled) on ainult 1 rida. See tähendab, et harvaesinevate kategooriate tulemused on statistiliselt ebastabiilsed.

Baasjoone valik on lihtsustatud. Käesolevas töös eeldatakse, et Swedbank määrab enamikule supermarketi tehingutest kategooria „Toidupoed". Teised pangad ja PFM-rakendused võivad kasutada erinevaid kategoriseerimisstrateegiaid.

2.5.5. Edasised sammud

Edasine töö hõlmab järgmisi arendussuundi. Klassifikaatori sõnastiku täiustamine, eelkõige lillede kategooria reeglite kitsendamine ja majapidamiskaupade sõnastiku laiendamine, parandaks otseselt klassifikaatori kvaliteeti. Andmestiku laiendamine teiste Eesti kauplustega ning pikemate perioodidega suurendaks tulemuste üldistamisvõimet. Masinõppepõhise klassifitseerimise võimaluste uurimine on pikemaajalisem arendussuund, mis võiks vähendada sõnastiku manuaalse haldamise vajadust. Need arendusülesanded jäävad käesoleva töö raamidest välja, kuid on loogiline jätk praegusele prototüübile.

KOKKUVÕTE

Käesoleva bakalaureusetöö eesmärk oli arendada ja hinnata Eesti tingimustele lokaliseeritud prototüüpi, mis kategoriseerib supermarketi kulud kassatšeki kaubaridade alusel, ning määrata kindlaks, kuivõrd see lähenemine on praktiliselt rakendatav võrreldes pangatehingu tasandi baasjoone kategooriaga.

Teoreetilises osas käsitleti isikliku finantsjuhtimise kulude kategoriseerimise lähenemisviise, tehingutasandi meetodi piiranguid, kviitungitelt andmete eraldamise võimalusi ning Eesti konteksti eripärasid. Analüüs näitas, et tehingutasandil kategoriseerimine on laialdaselt kasutatav ja skaleeritav, kuid ei kajasta supermarketi ostu koostist, mistõttu osa kuludest liigitub valesse kategooriasse.

Töö raames arendati prototüüp, mis automatiseerib kviitungite allalaadimise Maxima AITÄH portaalist, eraldab kaubaread tekstipõhistest PDF-kviitungitest, kategoriseerib iga kaubarea reeglistikupõhise klassifikaatori abil ja seostab kviitungid pangaväljavõttega. Prototüüp koosneb kolmest kihist: Node.js ja Playwright põhine allalaadimismoodul, Pythoni andmetöötlusahel (parse → categorize → match_bank → report) ning Electroni

töölauarakendus kasutajaliidesena. Prototüüp on uurimisvahend, mitte tootmisvalmis PFM-rakendus.

Pilootuuringus analüüsiti 114 Maxima kassatšekki ja 686 kaubareale perioodist 02.07.2025–26.03.2026. Tulemused näitasid, et 40% kassatšekkidest olid segasisuga ja 16,1% tegelikest tarbimiskuludest (291,67 EUR kogusummast 1813,68 EUR) kategoriseeriti baasjoone meetodil liiga üldiselt. Suurimad erinevused tekkisid majapidamis- ja puhastusvahendite (164,57 EUR, 9,1%) ning alkoholi ja tubaka (85,16 EUR, 4,7%) kategoorias.

Reeglistikupõhise klassifikaatori formaalne hindamine 200 käsitsi märgendatud kaubarea põhjal näitas üldtäpsust 87% ja makro-F1 skoori 0,78. Klassifikaator töötab hästi sagedasemate kategooriate puhul, kuid harvaesinevate kategooriate tulemused on ebastabiilsed väikese valimi tõttu.

Vastused uurimisküsimustele on järgmised. Esiteks, tehingutasandi kategoriseerimine on supermarketite puhul liiga üldine: 11,5% kaubaridadest ja 16,1% tarbimiskuludest kuulub teistesse kategooriatesse kui baasjoone meetod näitab. Teiseks, kassatšeki kaubaridade eraldamine ja reeglistikupõhine kategoriseerimine on Maxima tekstipõhiste PDF-kviitungite puhul automatiseeritav ning klassifikaator saavutab praktiliselt kasutatava kvaliteedi (accuracy 87%, F1 0,78), kuigi lillede ja alkoholi kategooria reeglid vajavad täpsustamist. Kolmandaks, peamised praktilised piirangud on seotud andmestiku esindavusega (ühe kasutaja andmed ühest jaeketist), klassifikaatori sõnastiku ulatusega ning kaupluste valikuga. Edasised sammud hõlmavad sõnastiku täiustamist, andmestiku laiendamist teiste kauplustega ning masinõppepõhise klassifitseerimise võimaluste uurimist.

Töö eesmärk on saavutatud: prototüüp on arendatud, pilootuuring on läbi viidud ning lähenemise praktiline rakendatavus ja piirangud Eesti kontekstis on kindlaks tehtud.

KASUTATUD KIRJANDUS

Aishwarya, S., & Hemalatha, S. (2023). Smart expense tracking system using machine learning. In Proceedings of the 1st International Conference on Artificial Intelligence for Internet of Things: Accelerating Innovation in Industry and Consumer Electronics (AI4IoT 2023) (pp. 634–639). https://doi.org/10.5220/0012613900003739

Bitrián, P., Buil, I., & Catalán, S. (2021). Making finance fun: the gamification of personal financial management apps. International Journal of Bank Marketing, 39(7), 1310–1332. https://doi.org/10.1108/IJBM-02-2021-0074

Eurostat. (2025). Household budget survey – statistics on consumption expenditure. https://ec.europa.eu/eurostat/statistics-explained/index.php/Household_budget_survey_-_statistics_on_consumption_expenditure

Garcia, M. B., & Claour, J. P. (2021). Mobile Bookkeeper: Personal financial management application with receipt scanner using optical character recognition. In 2021 1st Conference on Online Teaching for Mobile Education (OT4ME) (pp. 15–20). IEEE. https://doi.org/10.1109/OT4ME53559.2021.9638794

García-Méndez, S., Fernández-Gavilanes, M., Juncal-Martínez, J., González-Castaño, F. J., & Barba Seara, Ó. (2020). Identifying banking transaction descriptions via support vector machine short-text classification based on a specialized labelled corpus. IEEE Access, 8, 61642–61655. https://doi.org/10.1109/ACCESS.2020.2983584

Huang, Z., Chen, K., He, J., Bai, X., Karatzas, D., Lu, S., & Jawahar, C. V. (2019). ICDAR2019 competition on scanned receipt OCR and information extraction. In 2019 International Conference on Document Analysis and Recognition (ICDAR) (pp. 1516–1520). IEEE. https://doi.org/10.1109/ICDAR.2019.00244

Kotios, D., Makridis, G., Fatouros, G., & Kyriazis, D. (2022). Deep learning enhancing banking services: A hybrid transaction classification and cash flow prediction approach. Journal of Big Data, 9, Article 100. https://doi.org/10.1186/s40537-022-00651-x

Lesner, C., Ran, A., Rukonic, M., & Wang, W. (2019). Large scale personalized categorization of financial transactions. In Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence (AAAI-19), 33(01), 9365–9372. https://doi.org/10.1609/aaai.v33i01.33019365

Maxima Eesti. (s.a.). AITÄH lojaalsusprogramm. https://aitah.maxima.ee

Struwig, M., & Plaatjes, W. (2013). Developing a framework to investigate the personal financial management knowledge of individuals. South African Journal of Economic and Management Sciences, 10(1), 21–32. https://doi.org/10.4102/sajems.v10i1.534

Swedbank. (s.a.). My Budget. https://www.swedbank.ee

Toshl. (s.a.). Toshl Finance. https://toshl.com

United Nations. (2018). Classification of Individual Consumption According to Purpose (COICOP) 2018. Department of Economic and Social Affairs, Statistics Division. https://unstats.un.org/unsd/classifications/unsdclassifications/COICOP_2018_-_pre-edited_white_cover_version_-_2018-12-26.pdf

Wong, R. Y., & Tan, P. P. (2024). Receipt image extraction in budgeting mobile application. Trends in Undergraduate Research, 7(1), c16–25. https://doi.org/10.33736/tur.6110.2024

YNAB. (s.a.). You Need A Budget. https://www.ynab.com

LISAD

Lisa 1. Prototüübi kasutajaliidese kuvatõmmised

Joonis L1.1. Andmete kogumise vaade (Data collection)

Joonis L1.2. Parsimise ülevaate vaade (Parsing review)

Joonis L1.3. Kategoriseerimise ülevaate vaade (Categorization review)

Joonis L1.4. Baasjoone ja aruandluse vaade (Baseline & reporting)

Lisa 2. Kviitungi näidis ja andmete eraldamise näide

Joonis L2.1. Maxima kassatšeki PDF-faili näidis (isikuandmed eemaldatud)

Lisa 3. Kategoriseerimissõnastiku struktuur

Tabel L3.1. Kategoriseerimissõnastiku näidis kategooriate lõikes

Kategooria	Märksõnade näited (prototüübis categorize.py)
DEPOSIT (pandipakend; kulutuste arvestusest välja)	pandipakend, pet pudel, metallpurk, tagatisraha; lisaks is_deposit parseri märgistus
Alkohol ja tubakas	vein, õlu, siider, vodka, viski, rum, gin, prosecco, tubakas, sigaret
Majapidamistehnika	röster, kohvimasin, blender, mikser, tolmuimeja, külmkapp, tefal, philips, pann
Lilled ja kingitused	lill, krüsanteem, roos, tulp, lillekimp, kingitus
Majapidamis- ja puhastusvahendid	wc-paber, zewa, salvrätik, pesupulber, nõudepesuvahend, šampoon, hambapasta, näokreem, nivea, tampoon, kruus, taldrik, küünal
Toidukaubad ja alkoholivabad joogid	piim, jogurt, kana, leib, banaan, mineraalvesi, kohv, riis, šokolaad; ilma vasteta märksõnata — vaikimisi kategooria (fallback)
Muu	regex tagasimakse ridadele: tagastatud, tagasimakse, raha tagasi, tagasi saadud, возврат; unknown-haru müraridadele

Tabelis on toodud sõnastiku ja loogika näidis; täielik märksõnade loend ja prioriteetne kontrollijarjekord on failis analysis/categorize.py. Kategooria Muu ei ole samas failis pika sõnastikuna defineeritud, vaid sõltub eeskatt tagasimakse reeglist (regex) ja tundmatu rea heuristilisest reeglist. Kategooria Toidukaubad ja alkoholivabad joogid hõlmab ka ridu ilma eraldi märksõnata (vaikimisi oletus).